

Clasificación Supervisada

Detección de Cáncer de Mama — Wisconsin Dataset

72.75 Aprendizaje Automático — ITBA

Mayo 2026

El Dataset: Wisconsin Diagnostic Breast Cancer

- **569 muestras** · 30 features originales → **17 seleccionadas** tras limpieza
- Etiqueta binaria: Benigno (B=0) / Maligno (M=1)
- Features: mediciones del núcleo celular (radio, textura, perímetro, etc.)
- 3 grupos: `_mean`, `_se`, `_worst`
- Train: **455** muestras | Test: **114** muestras (80/20 estratificado)

B: 357 (62.7%) — Benigno

M: 212 (37.3%) — Maligno

⚠ Dataset desbalanceado → split estratificado obligatorio

Pipeline de Preprocesamiento

Raw Data (569×30) → Feature Selection (569×17) → Train/Test Split 80/20 → StandardScaler (dentro de CV)

- Eliminación de features correlacionadas ($|r| > 0.80$): **13 features removidas**
- Outliers **retenidos** — valores extremos son clinicamente significativos (mayormente malignos)
- Split 80/20 estratificado → preserva proporción B/M en ambos sets
- StandardScaler aplicado **DENTRO** del pipeline → sin data leakage

⚠ "Escalar antes del split contaminaría el test set con información del train. El scaler se ajusta solo sobre el fold de entrenamiento en cada iteración de CV."

Contexto Clínico: No todas las métricas son iguales

	Predicho M	Predicho B
Real M	TP ✓	FN ✗
Real B	FP ✗	TN ✓

- **FN:** tumor maligno → clasificado benigno → **no recibe tratamiento** → consecuencia grave
- FP: benigno → clasificado maligno → biopsia innecesaria → costoso pero no fatal
- Conclusión: **minimizar FN = maximizar Sensibilidad (Recall)**

● "En diagnóstico oncológico, un FN puede costar una vida. Optimizamos Recall."

Métricas clave — Definiciones

“ **Sensibilidad / Recall (TPR)** ● **MÉTRICA PRINCIPAL**

$TP / (TP + FN)$ — ¿De todos los enfermos, cuántos detectamos?

”

“ **Especificidad (TNR)**

$TN / (TN + FP)$ — ¿De todos los sanos, cuántos identificamos correctamente?

”

“ **VPP (Precisión)**

$TP / (TP + FP)$ — ¿De los clasificados como enfermos, cuántos lo son?

”

“ **VPN**

$TN / (TN + FN)$ — ¿De los clasificados como sanos, cuántos lo son?

”

Recall y Especificidad están en trade-off — aumentar uno tiende a bajar el otro

ROC-AUC y métricas complementarias

- **ROC** = curva TPR vs FPR para todos los umbrales posibles
- **AUC** = área bajo la curva = capacidad discriminativa general
- "Threshold-free" → útil para comparar modelos sin fijar umbral
- Segunda métrica: desempata entre modelos con recall similar


Métrica	Por qué no es la principal
Accuracy	Engañosa con desbalance (trivial = 62.7%)
F1-Score	Combina Recall+Precisión por igual
Precisión	Penaliza FP, no FN
MCC	Robusto pero difícil de interpretar

5 Clasificadores — Características

Modelo	Tipo	Tendencia natural
Naive Bayes	Generativo, paramétrico	Underfitting (asume independencia)
LDA	Discriminativo lineal	Underfitting (frontera lineal)
SVM (RBF)	Discriminativo, kernel	Overfitting si C alto
KNN	Basado en instancias	Depende de k: bajo k $\rightarrow$ overfit
Random Forest	Ensemble (bagging)	Overfit si max_depth sin límite

CV estratificado 5-fold en todos. Resultados de validación — test set NO fue tocado.


Paso 1: Baseline con hiperparámetros por defecto



- **SVM lidera:** Recall=**0.959**, ROC-AUC=**0.995**
- RF: Recall=**0.924** | KNN: Recall=**0.918** | NB: Recall=**0.906**
- **LDA más bajo:** Recall=**0.876** — frontera lineal insuficiente


Todos los resultados son de validación cruzada 5-fold — test set intacto

Análisis Bias-Varianza: Train vs CV



- **SVM**: gap mínimo → bien regularizado con C=1, kernel RBF
- **RF**: gap Recall ≈ 0.05 (max_depth=4) → overfitting borderline, árboles memorizan train
- **NB/LDA**: gap chico pero valores moderados → underfitting estructural
- **KNN**: gap moderado → sensible al valor de k


Gap Train – CV por modelo



- Umbral overfitting = **0.05** (línea roja en el gráfico)
- **RF** cruza umbral en Recall → max_depth debe controlarse
- SVM y NB por debajo del umbral → comportamiento estable


Gap bajo + CV alto = buen trade-off sesgo-varianza

Curva de Validación — Naive Bayes




- Parámetro: `var_smoothing` (escala logarítmica)
- NB tiene poca sensibilidad al smoothing → **underfitting estructural**
- Train y CV cerca → gap bajo, pero rendimiento moderado

Curva de Validación — LDA




- Parámetro: shrinkage (regularización)
- LDA con shrinkage leve mejora ROC-AUC (**0.989**)
- Train y CV convergen → gap bajo

Curva de Validación — SVM (C)




- **C óptimo ~1-10**; C muy alto → overfit
- Kernel RBF con C=1 ya es estable → default razonable

Curva de Validación — KNN (k vecinos)




- **k óptimo 5–9**; k=1 overfittea, k grande underfittea
- Trade-off claro entre bias y varianza

Curva de Validación — RF (max_depth)




- **max_depth ≤ 4** mantiene gap bajo 0.05; ≥5 → overfitting claro
- Train alcanza 1.0 desde depth=8 → memoriza, gap crece a 0.07

GridSearchCV — SVM




- GridSearch confirmó: **C=1.0, kernel=rbf** → Recall CV = **0.959**
- Kernel lineal consistentemente inferior

GridSearchCV — KNN




- GridSearch halló: **k=3, weights=uniform** → Recall CV = **0.924**
- Default k=5 → Recall **0.918** — gap aceptable (0.010), suficiente para este dataset

GridSearchCV — Random Forest



- GridSearch halló: **max_depth=8, n_estimators=100** → Recall CV = **0.929**
- Se eligió **max_depth=4**: gap baja de 0.071 a 0.052 — reduce overfitting
- max_depth ≥5: train alcanza 1.0 → memoriza; max_depth=None gap idéntico a 8

Impacto del Tuning de Hiperparámetros



- **SVM**: sin cambio — C=1 confirmado óptimo por GridSearch
- **LDA**: Recall +0.006, ROC-AUC +0.002 (shrinkage=0.1) — única mejora sustancial
- **RF**: Recall -0.006 (max_depth=None → 4) — reduce gap de 0.071 a 0.052
- **KNN / NB**: sin cambio — defaults sklearn ya razonables



Selección del Modelo Final

El modelo se selecciona en base a los resultados de **validación cruzada** — NO de test.
El test set se evalúa **UNA SOLA VEZ**, sobre el modelo ya elegido. Usarlo para selección introduce optimistic bias.

Ranking por Recall CV (tuned)

#	Modelo	Recall CV	ROC-AUC CV
1	SVM (RBF, C=1)	0.959 ✓	0.995
2	RF (depth=4) / KNN (k=5)	0.918	0.987 / 0.980
3	NB	0.906	0.985
4	LDA	0.882	0.991

Evaluación en Test — SVM (RBF, C=1)



Recall	ROC-AUC	F1	Accuracy
0.929	0.995	0.940	0.956

- Recall test (0.929) $\approx$ Recall CV (0.959) $\rightarrow$ generaliza bien
- Solo **3 FN** de 42 muestras malignas
- ROC-AUC = 0.995 $\rightarrow$ discriminación casi perfecta

Conclusiones

Resultados

- SVM RBF: mejor clasificador (Recall CV=**0.959**)
- Todos superan 0.87 de Recall — dataset bien separable
- Tuning mejoró marginalmente — defaults razonables
- Pipeline con StandardScaler interno → sin data leakage

Lo que nos enseñaron los modelos

- Curvas de validación: trade-off bias-varianza claro (RF depth $\geq$ 5 → overfit, k=1 → overfit)
- GridSearch no siempre da la mejor opción: RF depth=8 óptimo en grid, pero depth=4 reduce overfitting real
- Tuning fue marginal excepto LDA (+0.006 con shrinkage) — defaults sklearn razonables
- Limitar max_depth en RF reduce gap pero también recall — trade-off inevitable

"Un modelo clínico debe optimizar lo que importa: detectar enfermos. La métrica es la hipótesis."