

Clasificación Supervisada

Detección de Cáncer de Mama — Wisconsin Dataset

Pedro Curti · Felipe Hiba · Gonzalo Shariff

72.75 Aprendizaje Automático — ITBA

Mayo 2026

El Dataset: Wisconsin Diagnostic Breast Cancer

- **569 muestras** · 30 features originales → **17 seleccionadas** tras limpieza
- Etiqueta binaria: Benigno (B=0) / Maligno (M=1)
- Features: mediciones del núcleo celular (radio, textura, perímetro, etc.)
- 3 grupos: `_mean`, `_se`, `_worst`
- Train: **455** muestras | Test: **114** muestras (80/20 estratificado)

B: 357 (62.7%) — Benigno

M: 212 (37.3%) — Maligno

Dataset desbalanceado → split estratificado obligatorio


Pipeline de Preprocesamiento

Raw Data (569×30) → Feature Selection (569×17) → Train/Test Split 80/20 → StandardScaler (dentro de CV)

- Eliminación de features correlacionadas ($|r| > 0.80$): **13 features removidas**
- Outliers **retenidos** — valores extremos son clinicamente significativos (mayormente malignos)
- Split 80/20 estratificado → preserva proporción B/M en ambos sets
- StandardScaler aplicado **DENTRO** del pipeline → sin data leakage


"Escalar antes del split contaminaría el test set con información del train. El scaler se ajusta solo sobre el fold de entrenamiento en cada iteración de CV."

Feature Selection: Matriz de Correlación



- **78 pares** con $|r| > 0.70$ en el dataset original
- Se eliminaron **13 features** por multicolinealidad ($|r| > 0.80$)
- De cada grupo correlacionado se conserva la feature con mayor $|r(\text{diagnosis})|$

Correlación de Features con Diagnosis



- Features con $|r| \geq 0.5$ (violeta) son las más discriminativas
- `concave_points_worst` ($r = +0.79$) y `perimeter_worst` ($r = +0.78$) lideran
- Features con $|r| < 0.1$ (ej: `texture_se`, `symmetry_se`) barely aportan señal

Contexto Clínico: No todas las métricas son iguales

	Predicho M	Predicho B
Real M	TP ✓	FN ✗
Real B	FP ✗	TN ✓

- **FN:** tumor maligno → clasificado benigno → **no recibe tratamiento** → consecuencia grave
- FP: benigno → clasificado maligno → biopsia innecesaria → costoso pero no fatal
- Conclusión: **minimizar FN = maximizar Sensibilidad (Recall)**

"En diagnóstico oncológico, un FN puede costar una vida. Optimizamos Recall."

Métricas clave — Definiciones

Sensibilidad / Recall (TPR) **MÉTRICA PRINCIPAL**

$TP / (TP + FN)$ — ¿De todos los enfermos, cuántos detectamos?

Especificidad (TNR)

$TN / (TN + FP)$ — ¿De todos los sanos, cuántos identificamos correctamente?

VPP (Precisión)

$TP / (TP + FP)$ — ¿De los clasificados como enfermos, cuántos lo son?

VPN

$TN / (TN + FN)$ — ¿De los clasificados como sanos, cuántos lo son?

Recall y Especificidad están en trade-off — aumentar uno tiende a bajar el otro

ROC-AUC y métricas complementarias

- **ROC** = curva TPR vs FPR para todos los umbrales posibles
- **AUC** = área bajo la curva = capacidad discriminativa general
- "Threshold-free" → útil para comparar modelos sin fijar umbral
- Segunda métrica: desempata entre modelos con recall similar


Métrica	Por qué no es la principal
Accuracy	Engañosa con desbalance (trivial = 62.7%)
F1-Score	Combina Recall+Precisión por igual
Precisión	Penaliza FP, no FN
MCC	Robusto pero difícil de interpretar

5 Clasificadores — Características

Modelo	Tipo	Tendencia natural
Naive Bayes	Generativo, paramétrico	Underfitting (asume independencia)
LDA	Discriminativo lineal	Underfitting (frontera lineal)
SVM (RBF)	Discriminativo, kernel	Overfitting si C alto
KNN	Basado en instancias	Depende de k: bajo k $\rightarrow$ overfit
Random Forest	Ensemble (bagging)	Overfit si max_depth sin límite


CV estratificado 5-fold en todos los modelos.

Paso 1: Baseline con hiperparámetros por defecto




- **SVM lidera:** Recall=0.959, ROC-AUC=0.995
- RF: Recall=0.924 | KNN: Recall=0.918 | NB: Recall=0.906
- **LDA más bajo:** Recall=0.876 — frontera lineal insuficiente

Análisis Bias-Varianza: Train vs CV



- **SVM**: gap mínimo → bien regularizado con $C=1$, kernel RBF
- **RF**: gap Recall ≈ 0.05 ($\text{max_depth}=4$) → overfitting borderline, árboles memorizan train
- **NB/LDA**: gap chico pero valores moderados → underfitting estructural
- **KNN**: gap moderado → sensible al valor de k


Gap Train – CV por modelo



- Umbral overfitting = **0.05** (línea roja en el gráfico)
- **RF** cruza umbral en Recall → max_depth debe controlarse
- SVM y NB por debajo del umbral → comportamiento estable


Gap bajo + CV alto = buen trade-off sesgo-varianza

Curva de Validación — Naive Bayes




- Parámetro: `var_smoothing` (escala logarítmica)
- NB tiene poca sensibilidad al smoothing → **underfitting estructural**
- Train y CV cerca → gap bajo, pero rendimiento moderado

Curva de Validación — LDA




- Parámetro: `shrinkage` (regularización)
- LDA con shrinkage leve mejora ROC-AUC (**0.989**)
- Train y CV convergen → gap bajo

Curva de Validación — SVM (C)




- **C óptimo ~1-10**; C muy alto → overfit
- Kernel RBF con C=1 ya es estable → default razonable

Curva de Validación — KNN (k vecinos)




- **k óptimo 5–9**; k=1 overfittea, k grande underfittea
- Trade-off claro entre bias y varianza

Curva de Validación — RF (max_depth)




- `max_depth ≤ 4` mantiene gap bajo 0.05; `≥ 5` → overfitting claro
- Train alcanza 1.0 desde `depth=8` → memoriza, gap crece a 0.07

GridSearchCV — SVM




- GridSearch confirmó: **C=1.0**, **kernel=rbf** → Recall CV = **0.959**
- Kernel lineal consistentemente inferior

GridSearchCV — KNN




- GridSearch halló: **k=3, weights=uniform** → Recall CV = **0.924**
- Default k=5 → Recall **0.918** — gap aceptable (0.010), suficiente para este dataset

GridSearchCV — Random Forest



- GridSearch halló: **max_depth=8, n_estimators=100** → Recall CV = **0.929**
- Se eligió **max_depth=4**: gap baja de 0.071 a 0.052 — reduce overfitting
- **max_depth ≥ 5**: train alcanza 1.0 → memoriza; **max_depth=None** gap idéntico a 8

Impacto del Tuning de Hiperparámetros



- **SVM**: sin cambio — C=1 confirmado óptimo por GridSearch
- **LDA**: Recall +0.006, ROC-AUC +0.002 (shrinkage=0.1) — única mejora sustancial
- **RF**: Recall -0.006 (max_depth=None → 4) — reduce gap de 0.071 a 0.052
- **KNN / NB**: sin cambio — defaults sklearn ya razonables



Selección del Modelo Final

El modelo se selecciona en base a los resultados de **validación cruzada** — NO de test.
El test set se evalúa **UNA SOLA VEZ**, sobre el modelo ya elegido. Usarlo para selección introduce optimistic bias.

Ranking por Recall CV (tuned)

#	Modelo	Recall CV	ROC-AUC CV
1	SVM (RBF, C=1)	0.959 ✓	0.995
2	RF (depth=4) / KNN (k=5)	0.918	0.987 / 0.980
3	NB	0.906	0.985
4	LDA	0.882	0.991

Evaluación en Test — SVM (RBF, C=1)



Recall	ROC-AUC	F1	Accuracy
0.929	0.995	0.940	0.956

- Recall test (0.929) $\approx$ Recall CV (0.959) $\rightarrow$ generaliza bien
- Solo **3 FN** de 42 muestras malignas
- ROC-AUC = 0.995 $\rightarrow$ discriminación casi perfecta

Conclusiones

Resultados

- SVM RBF: mejor clasificador (Recall CV=**0.959**)
- Todos superan 0.87 de Recall — dataset bien separable
- Tuning mejoró marginalmente — defaults razonables
- Pipeline con StandardScaler interno → sin data leakage

Lo que nos enseñaron los modelos

- Curvas de validación: trade-off bias-varianza claro (RF depth $\geq$ 5 → overfit, k=1 → overfit)
- GridSearch no siempre da la mejor opción: RF depth=8 óptimo en grid, pero depth=4 reduce overfitting real
- Tuning fue marginal excepto LDA (+0.006 con shrinkage) — defaults sklearn razonables
- Limitar max_depth en RF reduce gap pero también recall — trade-off inevitable

"Un modelo clínico debe optimizar lo que importa: detectar enfermos. La métrica es la hipótesis."