


72.75 Aprendizaje Automático — ITBA

Clasificación Supervisada

Detección de Cáncer de Mama — Wisconsin
Dataset



Wisconsin Breast Cancer Dataset

569

Muestras

17

Features

357

Benigno

212

Maligno

- 30 features originales → 17 tras eliminar correlaciones ($|r| > 0.95$)
- Etiqueta binaria: Benigno (B=0) / Maligno (M=1)
- Mediciones del núcleo celular: radio, textura, perímetro, área, suavidad, etc.
- Train 455 | Test 114 — split 80/20 estratificado

Dataset desbalanceado → split estratificado obligatorio

Pipeline de Preprocesamiento




Raw Data

569 × 30




Limpieza

Eliminar $|r| > 0.95 \rightarrow 17$
features



Split

80/20 estratificado



Scaling

StandardScaler dentro del
pipeline

Escalar antes del split contaminaría el test set con información del train. El scaler se ajusta SOLO sobre el fold de entrenamiento en cada iteración de CV.

Contexto Clínico

TP

Maligno → Maligno

FP

Benigno → Maligno

FN

Maligno → Benigno

EL PELIGROSO

TN

Benigno → Benigno

FN = tumor maligno no detectado → paciente sin tratamiento

FP = biopsia innecesaria → costoso, no fatal

Minimizar FN = maximizar Recall. En oncología, un FN puede costar una vida.

Métricas Clave

PRINCIPAL

Recall / TPR

$$TP / (TP + FN)$$

¿De todos los enfermos, cuántos detectamos?

Especificidad / TNR

$$TN / (TN + FP)$$

¿De todos los sanos, cuántos identificamos?

Precisión / VPP

$$TP / (TP + FP)$$

¿De los clasificados como enfermos, cuántos lo son?

VPN

$$TN / (TN + FN)$$

¿De los clasificados como sanos, cuántos lo son?

Recall y Especificidad están en trade-off

ROC-AUC

ROC-AUC

- Curva TPR vs FPR para todos los umbrales
- AUC = capacidad discriminativa general
- Threshold-free: compara modelos sin fijar umbral
- Segunda métrica de ranking para desempatar

Métricas descartadas

Métrica	Por qué no
Accuracy	Engañosa con clases desbalanceadas
F1-Score	Combina Recall + Precision por igual
Precision (VPP)	Penaliza FP, no FN → prioridad incorrecta
MCC	Robusto pero difícil de interpretar

Reportamos F1 y Accuracy como secundarias para completitud.

Clasificadores


Evaluados

Modelo	Tipo	Tendencia
Naive Bayes	Generativo	Underfitting (independencia de features)
LDA	Lineal discriminativo	Underfitting (frontera lineal)
SVM (RBF)	Kernel discriminativo	Overfitting si C alto
KNN	Basado en instancias	Overfit con k bajo
Random Forest	Ensemble (bagging)	Overfit sin límite de profundidad

CV estratificado 5-fold en todos los modelos. Test set intacto.

Baseline CV

Hiperparámetros default





SVM lidera: Recall=0.959, ROC-AUC=0.995

NB y KNN empatan: Recall=0.906

LDA más bajo: Recall=0.876

Bias-Varianza


Analisis bias-varianza -- Train vs CV



Insights

- SVM: gap mínimo → bien regularizado
- RF: gap ~0.07 → overfitting leve
- NB/LDA: gap chico → underfitting
- KNN: gap moderado → sensible a k

Overfitting Gaps






Umbral = 0.05 (línea roja)




RF cruza umbral → controlar max_depth

Gap bajo + CV alto = buen trade-off


Curvas de Validación



GridSearchCV



Impacto del Tuning



- SVM: sin cambio — C=1 era default óptimo
- RF: leve mejora (+0.005) con n_estimators=200
- LDA: mejora ROC-AUC con shrinkage=0.1
- KNN: sin mejora significativa

Modelo Final

El modelo se selecciona por validación cruzada — NO por test set.

El test set se evalúa UNA SOLA VEZ. Usarlo para selección introduce optimistic bias.

Ranking por Recall CV tuned:

1	SVM	0.959	✓ seleccionado
2	RF	0.929	
3	KNN / NB	0.906	
4	LDA	0.882	

SVM

Kernel RBF



$C = 1$

Recall CV = 0.959

ROC-AUC CV = 0.995

Evaluación Test

SVM (RBF, C=1)



Recall	ROC-AUC	F1	Accuracy
0.929	0.995	0.940	0.956

- Recall test (0.929) $\approx$ Recall CV (0.959) $\rightarrow$ generaliza bien
- 3 FN de 42 muestras malignas
- ROC-AUC = 0.995 $\rightarrow$ discriminación casi perfecta

Conclusiones

Resultados

- SVM RBF = mejor clasificador (Recall CV 0.959)
- Todos los modelos > 0.87 Recall
- Tuning marginal — defaults razonables
- Pipeline con scaler interno = no data leakage

Metodología

- La métrica define el problema: Accuracy confunde, Recall aclara
- CV estratificado indispensable con clases desbalanceadas
- Análisis train/CV > test para decisiones de diseño
- Separar selección (CV) de evaluación (test) es no-negociable

"Un modelo clínico debe optimizar lo que importa: detectar enfermos. La métrica es la hipótesis."